

Estatística Computacional

Plancha; 105289; CDB2
Versão 1.0

Teoria de Probabilidades

Esperiência aleatória	Processo de observação de fenómenos aleatórios
Fenómenos aleatórios	Acontecimentos não determináveis <i>a priori</i>
Espaço de resultados	Ω Conjunto de todos os resultados possíveis
Acontecimentos	A, B, C Conjunto de possíveis resultados de uma experiência
Resultado da experiência aleatória	ω A realizou-se se $\omega \in A$

Álgebra dos acontecimentos

União

$$A \cup B = \{\omega : \omega \in A \vee \omega \in B\}$$

Intersecção

$$A \cap B = \{\omega : \omega \in A \wedge \omega \in B\}$$

Diferença

$$A - B = A \setminus B = \{\omega : \omega \in A \wedge \omega \notin B\}$$

$$\Omega - B = \overline{B} = \{\omega : \omega \in \Omega \wedge \omega \notin B\}$$

Propriedades

Comutativa	$A \cup B = B \cup A$ $A \cap B = B \cap A$
Associativa	$A \cup (B \cap C) = (A \cup B) \cap C$ $A \cap (B \cup C) = (A \cap B) \cup C$
Distributiva	$A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$ $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$
Idempotência	$A \cup A = A$ $A \cap A = A$
Lei do Complemento	$A \cup \overline{A} = \Omega$ $A \cap \overline{A} = \emptyset$

Probabilidades (Cont)

Elemento Neutro	$A \cup \emptyset = A$ $A \cap \Omega = A$
Elemento Absorvente	$A \cup A = A$ $A \cap \emptyset = \emptyset$
Leis de Morgan	$\overline{A \cup B} = \overline{A} \cap \overline{B}$ $\overline{A \cap B} = \overline{A} \cup \overline{B}$

Probabilidades

a priori:

$$P[A] = \frac{n_A}{N}$$

a posteriori:

$$f_A = \frac{N_A}{N}$$

$$P[A] = \lim_{N \rightarrow \infty} f_A$$

Definições

\overline{A}	$\Omega - A$
$P[A]$	Probabilidade de A
n_A	Número de resultados favoráveis a A
N	Número de resultados possíveis
f_A	Frequência relativa de A
N_A	Número de vezes que A se verificou
$P[A B]$	Probabilidade de A dado que B se verificou

Axiomas

$$\forall A \subseteq \Omega : 0 \leq P[A] \leq 1$$

$$P[\Omega] = 1$$

Independência/Acontecimentos mutualmente exclusivos:

$$\forall A, B \subseteq \Omega \ni A \cap B = \emptyset : P[A \cup B] = P[A] + P[B]$$

Teoremas

$$P[\overline{A}] = 1 - P[A]$$

$$P[\emptyset] = 0$$

$$P[B - A] = P[B] - P[A \cap B]$$

$$P[A \cup B] = P[A] + P[B] - P[A \cap B]$$

$$P[A \cup B \cup C] = P[A] + P[B] + P[C] - P[A \cap B] - P[A \cap C] - P[B \cap C] + P[A \cap B \cap C]$$

$$P[A \cup B] \leq P[A] + P[B]$$

$$P[A | B] = \frac{P[A \cap B]}{P[B]} \quad \text{se } P[B] > 0$$

$$P[A | B] = 0 \quad \text{se } P[B] = 0$$

Para acontecimentos independentes:

$$P[A \cap B] = P[A] \cdot P[B]$$

$$P[A | B] = P[A]$$

n partições:

$$\cup_{i=1}^n A_i = \Omega$$

$$A_i \cap A_j = \emptyset$$

$$P[A_i] > 0$$

Teorema da Probabilidade total:

$$\forall B \subseteq \Omega : P[B] = \sum_{i=1}^n P[A_i \cap B]$$


$$\forall B \subseteq \Omega : P[B] = \sum_{i=1}^n P[A_i | B] \cdot P[B]$$

Fórmula de Bayes:

$$P[A_j | B] = \frac{P[A_j] \cdot P[B | A_j]}{\sum_{i=1}^n P[A_i] \cdot P[B | A_i]}$$

Variáveis aleatórias

$$P[X = x] = P[A] = P[\omega \in \Omega : X(\omega) = x]$$



Variável aleatória $X(\omega)$ ou X Função que cada acontecimento ω associa um valor real $x = X(\omega)$

CD de uma Variável aleatória $X(\Omega)$

Função (massa) de probabilidade

X é discreto

$$f(x) = P[X = x]$$

$$0 \leq f(x) \leq 1$$

$$\sum_{i=1}^n f(x_i) = 1 \quad \text{caso } n \text{ finito}$$

$$\sum_{i=1}^{\infty} f(x_i) = 1 \quad \text{caso } n \text{ infinito}$$

Função densidade de probabilidade

X é contínuo, e é comum a função ser parametrizada (p.e. $f(x; \mu, \sigma^2)$), dependendo da distribuição de X

$$f(x) = \frac{d}{dx} F(x)$$

$$0 \leq f(x) \leq 1$$

$$\int_{-\infty}^{\infty} f(x) dx = 1$$

$$P[X = x] = 0 \quad f(x) \neq 0$$

Função de distribuição (acomulada) (f.d.p.)

A função é apenas crescente

$$F(x) = P[X \leq x]$$

$$0 \leq F(x) \leq 1$$

$$\forall x_2 > x_1 :$$

$$F(x_2) \geq F(x_1)$$

$$\wedge F(x_2) - F(x_1) = P[x_1 < X \leq x_2]$$

$$\lim_{x \rightarrow -\infty} F(x) = 0$$


$$\lim_{x \rightarrow \infty} F(x) = 1$$

$$P[x_1 < X \leq x_2] = F(x_2) - F(x_1)$$

Se X for contínua:

$$F(x) = P[X \leq x] = \int_{-\infty}^x f(u) du$$

$$P[x_1 < X \leq x_2] = \int_{x_1}^{x_2} f(u) du$$



Função de probabilidade conjunta

Se discretas

$$f(x, y) = P[X = x, Y = y] = P[X = x \cap Y = y]$$

$$0 \leq f(x, y) \leq 1$$

$$\sum_{i=1}^n \sum_{j=1}^n f(x_i, y_j) = 1$$

$$F(x, y) = P[X \leq x, Y \leq y] = \sum_{x_i \leq x} \sum_{y_j \leq y} f(x_i, y_j)$$

$$\lim_{x \rightarrow -\infty \wedge y \rightarrow -\infty} F(x, y) = 0$$

$$\lim_{x \rightarrow \infty \wedge y \rightarrow \infty} F(x, y) = 1$$

$$\forall \lambda \in \mathbb{R} :$$

$$\lim_{x \rightarrow -\infty} F(x, \lambda) = \lim_{y \rightarrow -\infty} F(\lambda, y) = 0$$

$$\forall x_2 > x_1, y_2 > y_1 : F(x_2, y_2) \geq F(x_1, y_1)$$

Se contínuas

$$f(x, y) = \frac{\partial^2 F(x, y)}{\partial x \partial y}$$

$$F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) dv du$$

Parâmetros de v.a.s

Valor esperado

O valor esperado de X é igual à média de X .

$$E[X] = \mu_X = \mu$$

Se X for discreta:

$$E[X] = \sum_i x_i \cdot f(x_i)$$

Se X for contínua:

$$E[X] = \int x \cdot f(x) dx$$

Propriedades

$$\begin{aligned}E[\lambda] &= \lambda \\E[\lambda X] &= \lambda E[X] \\E[X \pm Y] &= E[X] \pm E[Y] \\E[XY] &= E[X]E[Y] \iff \text{se } X \text{ e } Y \text{ forem independentes} \\E[g(X)] &= \sum_i g(x_i) \cdot f(x_i) \iff \text{se } X \text{ for discreta} \\E[g(X)] &= \int g(x) \cdot f(x)dx \iff \text{se } X \text{ for cont  ua} \\E[X^2] &= \sum_i x_i^2 \cdot f(x_i) \iff \text{se } X \text{ for discreta}\end{aligned}$$

Vari  ncia

$$\begin{aligned}\sigma_X^2 &= \sigma_X^2 = \sigma^2 \\ \sigma_X^2 &= E[(X - E[X])^2] \\ \sigma_X^2 &= E[X^2] - E[X]^2 \\ \sigma_X^2 &= E[X^2] - \mu^2 \\ \sigma_X^2 &= \sum_i (x_i - \mu)^2 \cdot f(x_i) \iff \text{se } X \text{ for discreta} \\ \sigma_X^2 &= \int (x - E[X])^2 \cdot f(x)dx \iff \text{se } X \text{ for cont  ua} \\ \text{Var}(\lambda) &= 0 \\ \text{Var}(\lambda X) &= \lambda^2 \sigma_X^2 \\ \text{Var}(X \pm Y) &= \sigma_X^2 + \sigma_Y^2 \pm 2cov(X, Y) \\ \sigma &= \sqrt{\sigma^2} \\ Cov(X, Y) &= E[(X - \mu_X)(Y - \mu_Y)] \\ Cov(X, Y) &= E[X \cdot Y] - \mu_x \cdot \mu_y \\ Cov(X, Y) &= 0 \iff X \text{ e } Y \text{ s  o independentes}\end{aligned}$$

Sendo:

$$W = \frac{X - \mu_X}{\sigma}$$

, $E(W) = 0$ e $\sigma_W^2 = 1$.

Distribui  es te  ricas discretas

Uniforme

$$\begin{aligned}f(x; N) &= \begin{cases} \frac{1}{N} & \text{se } x \in \{1, 2, \dots, N\} \\ 0 & \text{se n  o} \end{cases} \\ F(x; N) &= \begin{cases} 0 & \text{se } x < 1 \\ \frac{x}{N} & \text{se } 1 \leq x \leq N \\ 1 & \text{se } x > N \end{cases} \\ E[X] &= \frac{N + 1}{2} \\ \sigma_X^2 &= \frac{N^2 - 1}{12}\end{aligned}$$

Distribui  o de Bernoulli

A distribui  o de Bernoulli   uma distribui  o binomial

$$\begin{aligned}f(x; p) &= \begin{cases} 1 - p & \text{se } x = 0 \\ p & \text{se } x = 1 \end{cases} \\ f(x; p) &= p^x (1 - p)^{1-x} \\ F(x; p) &= \begin{cases} 0 & \text{se } x < 0 \\ 1 - p & \text{se } 0 \leq x < 1 \\ 1 & \text{se } x \geq 1 \end{cases} \\ E[X] &= p \\ \sigma_X^2 &= p(1 - p)\end{aligned}$$

Distribui  o binomial

$$X \cap (n; p)$$

$$\begin{aligned}f(x; n, p) &= \begin{cases} \binom{n}{x} p^x (1 - p)^{n-x} & \text{se } x \in \{0, 1, \dots, N\} \\ 0 & \text{se n  o} \end{cases} \\ F(x; n, p) &= \begin{cases} 0 & \text{se } x < 0 \\ \sum_{i=0}^x \binom{n}{i} p^i (1 - p)^{n-i} & \text{se } 0 \leq x < n \\ 1 & \text{se } x \geq n \end{cases}\end{aligned}$$

$$\begin{aligned}E[X] &= np \\ \sigma_X^2 &= np(1 - p) \\ \sum_{i=1}^k X_i \cap b \left(\sum_{i=1}^k n_i; p \right) &\iff X_i \cap (n_i; p) \text{ s  o independentes}\end{aligned}$$

Processo de Poisson

$$X \cap p(\lambda; t)$$

$$\begin{aligned}f(x; \lambda, t) &= \begin{cases} \frac{e^{-t\lambda} (t\lambda)^x}{x!} & \text{se } x \in \mathbb{N} \\ 0 & \text{se n  o} \end{cases} \\ F(x; \lambda, t) &= \begin{cases} 0 & \text{se } x < 0 \\ e^{-t\lambda} \sum_{i=0}^x \frac{(t\lambda)^i}{i!} & \text{se } 0 \leq x < \infty \\ 1 & \text{se } x \geq \infty \end{cases}\end{aligned}$$

$$\begin{aligned}E[X] &= t\lambda \\ \sigma_X^2 &= t\lambda \\ \sum_{i=1}^k X_i \cap p \left(\sum_{i=1}^k t_i \lambda_i \right) &\iff X_i \cap p(\lambda_i, t_i) \text{ s  o independentes}\end{aligned}$$

Distribui  o de Poisson

A distribui  o de Poisson   um processo de Poisson onde t = 1

$$X \cap p(\lambda)$$

A distribui  o binomial converge para a distribui  o de Poisson quando $n \rightarrow \infty$ e $p \rightarrow 0$, sendo $\lambda = np$ constante.

$$\lim_{n \rightarrow \infty} b(n; p) = p(\lambda = np)$$

Distribui  es te  ricas cont  uas

Uniforme

$$\begin{aligned}f(x; a, b) &= \begin{cases} \frac{1}{b-a} & \text{se } a \leq x \leq b \\ 0 & \text{se } x < a \text{ ou } x > b \end{cases} \\ F(x; a, b) &= \begin{cases} 0 & \text{se } x < a \\ \frac{x-a}{b-a} & \text{se } a \leq x \leq b \\ 1 & \text{se } x > b \end{cases} \\ E[X] &= \frac{a + b}{2} \\ \sigma_X^2 &= \frac{(b - a)^2}{12}\end{aligned}$$

Normal

$$X \cap n(\mu, \sigma)$$

$$f(x; \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \cdot \exp\left(-\frac{1}{2}\left(\frac{(x-\mu)}{\sigma}\right)^2\right)$$

$$E[X] = \mu$$

$$\sigma_X^2 = \sigma^2$$

A normal normalmente transforma-se na normal padrão, com $\mu_Z = 0$ e $\sigma_Z = 1$, onde $Z = \frac{X-\mu_X}{\sigma_X}$. $F(x) > \phi(z)$, $f(x) > \varphi(z)$ e $F^{-1}(x) > \phi^{-1}(z)$ (função quantil)

$$\varphi(z) = \frac{1}{\sqrt{2\pi}} \cdot \exp\left(-\frac{1}{2}z^2\right)$$

$$P[\mu - \sigma < X < \mu + \sigma] = P[-1 < Z < 1] \approx 0.68$$

$$P[\mu - 2\sigma < X < \mu + 2\sigma] = P[-2 < Z < 2] \approx 0.95$$

$$P[\mu - 3\sigma < X < \mu + 3\sigma] = P[-3 < Z < 3] \approx 0.99$$

$$\phi^{-1}(0.95) = 1.645$$

$$\phi^{-1}(0.99) = 2.326$$

$$\phi^{-1}(0.95 + 0.05/2) = 1.96$$

$$\phi^{-1}(0.995) = 2.576$$

Aditividade:

$$T = \sum_{i=1}^k X_i \cap n(k\mu; \sigma\sqrt{k})$$

$$\iff X_i \cap n(\mu, \sigma) \text{ são independentes}$$

$$T = \sum_{i=1}^k a_i X_i \cap n\left(\sum a_i \mu_i; \sqrt{\sum a_i^2 \sigma_i^2}\right)$$

$$(X_1 \pm X_2) \cap n\left(\mu_1 \pm \mu_2; \sqrt{\sigma_1^2 + \sigma_2^2}\right)$$

$$X \cap n(np; \sqrt{np(1-p)}) \iff$$

$$\iff X \cap b(n, p), n \rightarrow \infty, 0.1 < p < 0.9$$

$$X \cap n(\lambda; \sqrt{\lambda}) \iff$$

$$\iff X \cap p(\lambda), \lambda \rightarrow \infty$$

Em termos práticos, $k \rightarrow \infty$ significa $k > 30$

Amostras

Amostras aleatórias

A variável aleatória (X_1, X_2, \dots, X_n) é uma amostra aleatória de uma população se:

$$f(x_1, x_2, \dots, x_n) = \prod (f(x_i))$$

, onde X_1 é o primeiro elemento da amostra, X_2 o segundo e X_n o n-ésimo.

Cada estatística (amostral) é uma variável aleatória

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad \text{Média amostral}$$

$$S^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 \quad \text{Variância amostral}$$

$$S'^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad \text{Variância amostral corrigida}$$

Teorema do limite central

$$\frac{\sum (X_i) - n\mu}{\sigma\sqrt{n}} \cap n(0, 1)$$

$$\sum X_i \cap n(n\mu, \sigma\sqrt{n})$$

$$\text{Como } \frac{\sum X_i}{n} = \bar{X} :$$

$$\bar{X} \cap n\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

Se e apenas se:

$$E[X_1] = E[X_2] = \dots = E[X_n] = \mu,$$

$$\text{Var}[X_1] = \text{Var}[X_2] = \dots = \text{Var}[X_n] = \sigma^2,$$

$$n \rightarrow \infty.$$

Distribuições de amostras de populações

Populações Bernoulli

$$\bar{X} \cap n\left(p, \sqrt{\frac{pq}{n}}\right)$$

$$(\bar{X}_1 - \bar{X}_2) \cap n\left(p_1 - p_2, \sqrt{\frac{p_1 q_1}{n_1} + \frac{p_2 q_2}{n_2}}\right)$$

Populações normais

quando σ^2 é conhecida:

$$\bar{X} \cap n\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

quando σ^2 é desconhecida:

$$\frac{\bar{X} - \mu}{\frac{S'}{\sqrt{n}}} \cap t_{n-1}$$

$$\frac{(n-1)S'^2}{\sigma^2} \cap \chi_{n-1}^2$$

$$\frac{nS'^2}{\sigma^2} \cap \chi_{n-1}^2$$

$$\bar{X}_1 - \bar{X}_2 \cap n\left(\mu_1 - \mu_2, \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}\right)$$

$$\bar{X}_1 - \bar{X}_2 \cap n\left(\mu_1 - \mu_2, \sqrt{\frac{S_1'^2}{n_1} + \frac{S_2'^2}{n_2}}\right)$$

Estimação de parâmetros

Um estimador para um parâmetro θ designa-se por $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ e é uma v.a. em função de uma amostra. A estimativa representa-se por $\hat{\theta}^*$.

Erro amostral = $\hat{\theta} - \theta$

Envesiamento = $\text{env}(\hat{\theta}) = E[\hat{\theta}] - \theta$

Propriedades

Considera-se que o estimador $\hat{\theta}_1$ é preferível ao estimador $\hat{\theta}_2$ para um intervalo $[a, b]$ se:

$$P[a < \hat{\theta}_1 < b] > P[a < \hat{\theta}_2 < b]$$

$\hat{\theta}$ é não enviesado/centrado se $E[\hat{\theta}] = \theta$

$\hat{\theta}_1$ é mais eficiente que $\hat{\theta}_2$ se $\text{Var}[\hat{\theta}_1] \leq \text{Var}[\hat{\theta}_2]$, se ambos forem enviesados ou consistentes em média quadrática.

$\hat{\theta}$ é suficiente se utiliza toda a informação disponível na amostra.

Para amostras grandes $(\hat{\theta}_n)$,:

$\hat{\theta}_n$ é não enviesado assintoticamente se:

$$\lim_{n \rightarrow \infty} E[\hat{\theta}_n] = \theta$$

$\hat{\theta}_n$ é consistente simples se

$$\lim_{n \rightarrow \infty} P\left[\left|\hat{\theta}_n - \theta\right| \leq \epsilon\right] = 1 \forall \epsilon > 0$$

$\hat{\theta}_n$ é consistente em média quadrática se

$$\begin{aligned} \lim_{n \rightarrow \infty} E\left[\left(\hat{\theta}_n - \theta\right)^2\right] &= \\ &= \lim_{n \rightarrow \infty} \left(\text{Var}[\hat{\theta}_n] = 0 + \left(\text{env}(\hat{\theta}_n)\right)^2\right) = 0 \end{aligned}$$

Estimação por intervalos

Dado uma variável fulcral Z , :

$$P\left[-\phi^{-1}(\lambda + 1 - \lambda/2) < Z < \phi^{-1}(\lambda + 1 - \lambda/2)\right] = \lambda$$

; Sendo λ o nível de confiança. Ou seja, a probabilidade do intervalo $]I_\lambda[_\theta$ de conter o parâmetro θ é λ . Por outras palavras, se fossem recolhidas n amostras aleatórias e fosse calculado o intervalo, $100\lambda\%$ desses intervalos conteriam o parâmetro θ .

Variáveis fulcrais

Variável Fulcral	θ	População	Dimensão
$\frac{\bar{x}-\mu}{\frac{\sigma}{\sqrt{n}}} \cap \text{n}(0,1)$	μ	Normal	Qualquer
$\frac{\bar{x}-\mu}{\frac{\sigma}{\sqrt{n}}} \overset{\circ}{\cap} \text{n}(0,1)$	μ	Qualquer	$n > 30$
$\frac{\bar{x}-\mu}{\frac{s}{\sqrt{n}}} \cap \text{t}_{n-1}$	μ	Normal	Qualquer
$\frac{\bar{x}-\mu}{\frac{s}{\sqrt{n}}} \overset{\circ}{\cap} \text{n}(0,1)$	μ	Qualquer	$n > 30$

Tipo de populações	Dimensão das amostras	Conhece-se σ_1^2 e σ_2^2 ?	Variável fulcral	Distribuição amostral
Normais	Quaisquer	Sim	$\frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$	N(0;1)
Normais	n_1 e $n_2 \leq 30$	Não, mas pode considerar-se $\sigma_1^2 = \sigma_2^2$	$\frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\frac{1}{\sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sqrt{\frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1 + n_2 - 2}}}$	$t_{(n_1+n_2-2)}$
Normais	n_1 e $n_2 \leq 30$	Não, e não se pode considerar $\sigma_1^2 = \sigma_2^2$	$\frac{(\bar{X}_1 - \bar{X}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$	$t_{(v)}$ com v dado por $\frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^{-1}}{\frac{s_1^4}{n_1(n_1+1)} + \frac{s_2^4}{n_2(n_2+1)}}$
Qualquer	n_1 e $n_2 > 30$	Não		Aprox. N(0;1)

Parâmetro a estimar	Tipo de população	Dimensão da amostra	Variável fulcral	Distribuição amostral
p	Bernoulli	$n > 30$	$\frac{\bar{X} - p}{\sqrt{p(1-p)/n}}$	Aprox. N(0;1)
p₁ - p₂	Bernoulli	$n_1 > 30 \wedge n_2 > 30$	$\frac{(\bar{X}_1 - \bar{X}_2) - (p_1 - p_2)}{\sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}}$	Aprox. N(0;1)
σ^2	Normal	qualquer	$\frac{(n-1)s_{-1}^2}{\sigma^2}$	$\chi^2_{(n-1)}$
$\frac{\sigma_1^2}{\sigma_2^2}$	Normal	qualquer	$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_1^2}$	$F_{(n_1-1; n_2-1)}$

NOTA: Em populações Bernoulli, na construção do IC há que substituir $p(1-p)$ por $\bar{X}(1-\bar{X})$

Com construir um intervalo de confiança:

- Definição da população, da sua distribuição e do parâmetro a estimar.
- Escolha da variável fulcral.
- Determinação da distribuição amostral da variável fulcral.
- Escolha do nível de confiança.
- Construção do intervalo aleatório.
- Determinação dos limites do intervalo aleatório.
- Determinação dos limites do intervalo de confiança concretos.

O intervalo concreto representa-se por $]I_\lambda[_\theta^*$, e o erro representa o que está a direita de θ no meu intervalo (p.e.:

$$\left] \bar{X} - \frac{z\sigma}{\sqrt{n}}, \bar{X} + \frac{z\sigma}{\sqrt{n}} \right[\iff \text{erro de estimação} = \frac{z\sigma}{\sqrt{n}}$$

)

Ensaio de hipóteses

Hipótese em questão: H_0 (Hipótese nula)

Hipótese alternativa: H_a

Quando as provas são incompatíveis com H_0 , então rejeita-se H_0 ; se tal não acontecer, não se rejeita H_0 .

Quando a decisão é errada:

Erro tipo I: H_0 é rejeitada quando é verdadeira.

Erro tipo II: H_0 não é rejeitada quando é falsa.

Nota: H_0 contem sempre a igualdade.

Passos

- Formulação das hipóteses
- Escolha do nível de significância α .

$$\alpha = P[\text{erro tipo I}] = P[\text{rejeitar } H_0 | H_0 \text{ é verdadeira}]$$

$$\alpha = F(\bar{x}_c) \equiv \bar{x}_c = F^{-1}(\alpha; \mu_{\bar{x}}, \sigma_{\bar{x}})$$

$$\bar{x}_c = \mu_{\bar{x}} + \phi^{-1}(\alpha)\sigma_{\bar{x}}$$

- Escolha da estatística e estabelecer a regra de decisão.

RC - região crítica ou de rejeição; Ra - região de aceitação ou de não aceitação.

Literalemngte dizer "Se $\hat{\theta} \in RC$, rejeitar H_0 ; se $\hat{\theta} \in Ra$, não se rejeita H_0 ."(sem ser com in se possivel)

Alternativamente dizer "Se $Z \in RC$, rejeitar H_0 etc"

- Tomada de decisão.

$p_1 - p_2$	Bernoulli	$n_1 > 30$ e $n_2 > 30$	$\frac{(\bar{X}_1 - \bar{X}_2) - (p_1 - p_2)_0}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}$, com $\hat{p} = \frac{n_1\bar{X}_1 + n_2\bar{X}_2}{n_1 + n_2}$	$\sim N(0,1)$
-------------	-----------	-------------------------	---	---------------

e o resto é igual só que o parâmetro é substituído pelo ponto a estimar

p.e.: $H_0 : \mu = 5$, então $\mu_0 = 5$

Quando é $\mu_1 - \mu_2$ é o parâmetro, então fica $(\mu_1 - \mu_2)_0$